Pengenalan Bahasa Isyarat BISINDO Berbasis Deep Learning

Klasifikasi 26 Kelas Alfabet Menggunakan YOLOv11n-cls

Top-1 Accuracy
98.0%

Praktikum Machine Learning — D3 Teknik Informatika

Semester 5 · 2026

Python 3.14 | PyTorch 2.11 + CUDA | Ultralytics YOLOv11 | Flask | RTX 3050

Dibuat otomatis pada 12 November 2026

1. Ringkasan Eksekutif

Proyek ini membangun sistem pengenalan **Bahasa Isyarat Indonesia (BISINDO)** untuk 26 kelas alfabet (A–Z) menggunakan pendekatan **klasifikasi gambar berbasis Deep Learning**. Model yang digunakan adalah **YOLOv11 Nano Classifier (yolo11n-cls)** dari Ultralytics, yang dilatih pada dataset 51.312 gambar dengan augmentasi dari Roboflow Universe.

Sistem ini mencapai akurasi **Top-1 sebesar 98,0%** dan **Top-5 sebesar 99,8%** setelah 50 epoch pelatihan selama ±6,3 jam pada GPU NVIDIA RTX 3050 6GB. Hasil penelitian dikemas dalam aplikasi web berbasis **Flask** yang mendukung deteksi real-time melalui kamera dan unggah gambar, dilengkapi fitur *word builder* dan *text-to-speech* Bahasa Indonesia.

Metrik	Nilai	Keterangan
Top-1 Accuracy	98,0%	Presisi kelas terbaik per gambar
Top-5 Accuracy	99,8%	Kelas benar masuk 5 prediksi teratas
Train Loss	0.11774	Loss akhir epoch 50 (train)
Validation Loss	0.05571	Loss akhir epoch 50 (val)
Inferensi	~6,5 ms	Per frame pada GPU RTX 3050
Ukuran Model	3,25 MB	File best.pt hasil training
Durasi Training	6,279 jam	50 epoch, batch=16, 224×224

2. Latar Belakang & Motivasi

BISINDO (Bahasa Isyarat Indonesia) adalah bahasa isyarat yang digunakan oleh komunitas Tuli di Indonesia. Berbeda dengan Sistem Isyarat Bahasa Indonesia (SIBI) yang bersifat formal, BISINDO berkembang secara alami di komunitas Tuli dan memiliki struktur gramatikal sendiri.

Keterbatasan komunikasi antara penyandang tunarungu dan masyarakat umum mendorong kebutuhan akan sistem penerjemah isyarat berbasis teknologi. Dengan memanfaatkan kamera yang tersedia di perangkat sehari-hari, sistem ini bertujuan menjembatani kesenjangan komunikasi tersebut secara real-time tanpa perangkat khusus.

Tujuan Proyek:

- Membangun model klasifikasi gambar untuk 26 huruf alfabet BISINDO (A–Z).
- Mencapai akurasi tinggi (>95%) menggunakan arsitektur YOLOv11n-cls.

- Mengintegrasikan model ke dalam aplikasi web real-time yang mudah digunakan.
- Menyediakan fitur bantu komunikasi: word builder, text-to-speech, panduan alfabet.

3. Dataset

3.1 Sumber Data

Dataset diperoleh dari **Roboflow Universe**, proyek **BISINDO** (workspace: *sijewi-jjr8b*, project: *bisindo-wb1lk*). Dataset ini diekspor pada 11 November 2026 pukul 03:16 WIB dalam format *Folder/ImageFolder* (satu folder per kelas) yang sesuai untuk pelatihan model klasifikasi.

Gambar asli berjumlah **21.508 gambar** yang kemudian diperbanyak melalui augmentasi otomatis menjadi **51.312 gambar** total. Lisensi dataset: CC BY 4.0.

3.2 Statistik Dataset

Split	Jumlah Gambar	Kelas	Persentase
Train	44.591	26 (A–Z)	86,9%
Valid	5.825	26 (A–Z)	11,4%
Test	896	26 (A–Z)	1,7%
Total	**51.312**	**26**	**100%**

3.3 Pre-Processing & Augmentasi

Tahap	Detail
Auto-Orientation	EXIF metadata dihapus, gambar dirotasi otomatis
Resize	224×224 piksel (Stretch) — sesuai input YOLOv11n-cls
Rotasi	±15° acak
Brightness	±21% penyesuaian kecerahan
Gaussian Blur	0 – 1,2 piksel
Salt & Pepper Noise	Tingkat noise 0,1%
Augmentation Factor	3× lipat dari gambar asli

3.4 Daftar Kelas (26 Huruf Alfabet)

A	B	C	D	E	F	G	H	I	J	K	L	M
N	O	P	Q	R	S	T	U	V	W	X	Y	Z

4. Mengapa Klasifikasi, Bukan Deteksi Objek?

Pemilihan pendekatan **klasifikasi gambar** dibandingkan **deteksi objek** untuk proyek ini didasarkan pada berbagai pertimbangan teknis dan karakteristik dataset BISINDO yang spesifik. Berikut analisis lengkapnya:

1. Struktur Dataset ImageFolder

Dataset BISINDO dari Roboflow diekspor dalam format ImageFolder (satu folder per kelas, tanpa file anotasi bounding box .txt). Format ini adalah format asli untuk klasifikasi. Memaksa penggunaan deteksi objek akan memerlukan anotasi ulang seluruh 51.312 gambar — pekerjaan yang tidak efisien dan tidak diperlukan.

2. Single-Label, Single-Instance per Gambar

Setiap gambar dalam dataset hanya mengandung SATU isyarat tangan yang sudah ter-crop atau ter-frame dengan baik. Deteksi objek dirancang untuk menemukan BANYAK objek dalam satu gambar dengan lokasi berbeda. Karena hanya ada satu objek per gambar, overhead komputasi bounding box regression tidak memberikan nilai tambah apapun.

3. Efisiensi Parameter Model

YOLOv11n-cls hanya memiliki 1,564,410 parameter (1,56M). Sebagai perbandingan, YOLOv11n (versi deteksi) memiliki ~2,6M parameter dengan tambahan detection head (Conv, DFL, Detect) yang tidak diperlukan. Model klasifikasi lebih ringan, lebih cepat dilatih, dan lebih cepat dijalankan.

4. Kecepatan Inferensi Lebih Tinggi

Model klasifikasi menghasilkan inferensi ~6,5ms/gambar (pada RTX 3050). Model deteksi dengan NMS (Non-Maximum Suppression) menambah latency tambahan ~8-15ms. Untuk aplikasi real-time 30 FPS, setiap milidetik berarti.

5. Tidak Ada Kebutuhan Lokalisasi

Tujuan sistem adalah MENGIDENTIFIKASI huruf apa yang ditampilkan, bukan MENEMUKAN DI MANA tangan berada dalam gambar. Lokalisasi (bounding box) adalah fitur tambahan yang tidak relevan untuk kasus ini.

6. Kompleksitas Training Lebih Rendah

Klasifikasi tidak memerlukan penyetelan anchor box, pengaturan IoU threshold, NMS threshold, atau format label YOLO (cx, cy, w, h). Pipeline training lebih sederhana, lebih cepat berkonvergensi, dan lebih

mudah di-debug.

7. Akurasi Lebih Tinggi pada Dataset Terstruktur

Dengan 44.591 gambar training yang sudah ter-frame rapi per kelas, model klasifikasi dapat memfokuskan seluruh kapasitasnya untuk membedakan TEKSTUR dan BENTUK tangan, menghasilkan Top-1 Accuracy 98,0% — jauh melebihi ekspektasi baseline model deteksi untuk kasus ini (~90-94%).

4.8 Tabel Perbandingan Komprehensif

Aspek	Klasifikasi (Dipilih)	Deteksi Objek
Tujuan	Identifikasi kelas gambar	Lokasi + identifikasi objek
Format Dataset	ImageFolder ✓	YOLO .txt bbox (tidak ada)
Parameter Model	1,56M (yolo11n-cls)	2,6M+ (yolo11n)
Inferensi	~6,5ms	~15-20ms (+ NMS)
Komponen Output	Softmax 26 kelas	Bbox (4) + Conf + 26 kelas
Perlu Anotasi BBox	Tidak	Ya (harus anotasi ulang)
Top-1 Accuracy	98,0% ✓	Estimasi ~90-94%
Cocok untuk Kasus	Single object, full-frame ✓	Multi object, berbagai ukuran
Kompleksitas Setup	Rendah (folder-based)	Tinggi (anchor, IoU, NMS)

5. Teknologi & Stack yang Digunakan

Komponen	Teknologi	Versi	Fungsi
Bahasa	Python	3.14.7	Bahasa pemrograman utama
DL Framework	PyTorch	2.11.0+cu128	Backend deep learning
CUDA	NVIDIA CUDA	12.8	GPU acceleration
YOLO Framework	Ultralytics	8.4.192	Model training & inference
Arsitektur	YOLOv11n-cls	nano-cls	Model klasifikasi ringan
Web Backend	Flask	3.x	REST API & web server
Frontend	HTML + Tailwind CSS	CDN	Antarmuka pengguna
Icons	Lucide Icons	CDN	Ikon UI modern
Kamera	OpenCV	4.x	Capture webcam & pemrosesan
Gambar	Pillow (PIL)	12.3.0	Manipulasi gambar upload
TTS	Web Speech API	Browser	Text-to-speech suara huruf
Dataset Mgmt	Roboflow	Universe	Sumber & augmentasi dataset
Hardware GPU	NVIDIA RTX 3050	6GB VRAM	Training & inference
Hardware CPU	Intel/AMD	Laptop	Fallback jika tanpa GPU
OS	Windows	11	Lingkungan pengembangan
PDF Report	ReportLab	5.1.0	Generasi laporan ini

6. Arsitektur Model YOLOv11n-cls

YOLOv11n-cls adalah varian paling ringan dari keluarga YOLO versi 11 yang dirancang khusus untuk tugas **klasifikasi gambar**. Model ini menggunakan backbone CSP (Cross Stage Partial) dengan modul C3k2 dan C2PSA untuk ekstraksi fitur yang efisien.

Parameter Model	Nilai
Jumlah Layer	86 layer

Total Parameter	1.564.410 (~1,56M)
GFLOPs	3,3 GFLOPs
Ukuran Input	224 × 224 × 3 (RGB)
Ukuran Output	26 (softmax probability)
Pre-trained Weights	ImageNet (transfer learning via COCO pretrain)
File Weights	best.pt — 3,25 MB
Format Model	PyTorch .pt (stripped optimizer)

6.1 Alur Layer Model

Layer	Komponen	Fungsi
Input	224×224×3 RGB Image	Entry point gambar
Conv	Stem Convolution (k=3, s=2)	Downsampling awal
C3k2	Cross Stage Partial (kecil)	Ekstraksi fitur dasar
Conv	Convolution (k=3, s=2)	Downsampling
C3k2	Cross Stage Partial (besar)	Fitur menengah
Conv	Convolution (k=3, s=2)	Downsampling
C3k2	Cross Stage Partial (besar)	Fitur dalam
Conv	Convolution (k=3, s=2)	Downsampling akhir
C3k2	Cross Stage Partial (sangat kecil)	Fitur global
C2PSA	Cross-Attention PSA Module	Attention mechanism
Classify	**Global Avg Pool → FC → Softmax(26)**	**Output 26 kelas**

7. Konfigurasi Training

Training dilakukan menggunakan Ultralytics Python API dengan konfigurasi berikut. Model di-fine-tune menggunakan transfer learning dari bobot pre-trained yolo11n-cls.pt untuk mempercepat konvergensi dan meningkatkan akurasi pada dataset BISINDO yang terbatas.

Parameter	Nilai	Keterangan
model	yolo11n-cls.pt	Base model pretrained
data	dataset/ (folder)	Path root dataset ImageFolder
epochs	50	Jumlah epoch pelatihan
imgsz	224	Ukuran input gambar (px)
batch	16	Batch size per iterasi
device	0 (CUDA GPU)	NVIDIA RTX 3050 6GB
name	yolov11_bisindo_cls_v2	Nama eksperimen/run
project	runs/classify/runs/classify/	Folder output
optimizer	Auto (AdamW→SGD)	Dipilih otomatis Ultralytics
amp	True	Mixed Precision Training
patience	50	Early stopping patience
workers	8	DataLoader worker threads
pretrained	True	Gunakan bobot pre-trained
dropout	0.0	Dropout (default)
lr0	0.01	Learning rate awal
lrf	0.01	Learning rate final ratio

8. Hasil Training & Akurasi

Top-1 Accuracy	Top-5 Accuracy	Val Loss	Train Loss

98,0%	99,8%	0.0557	0.1177
Epoch 50 Final	*Epoch 50 Final*	*Epoch 50 Final*	*Epoch 50 Final*

8.1 Progres Training per Epoch Kunci

Epoch	GPU Mem (G)	Train Loss	Top-1 Acc	Top-5 Acc	Val Loss
1	0.263	1.5247	0.7103	0.9435	0.5820
5	0.264	0.6823	0.8956	0.9789	0.2430
10	0.265	0.4215	0.9412	0.9891	0.1620
20	0.265	0.2876	0.9634	0.9951	0.1105
30	0.266	0.2103	0.9712	0.9969	0.0892
40	0.267	0.1534	0.9768	0.9978	0.0712
50	**0.271**	**0.1177**	**0.9799**	**0.9983**	**0.0557**

** Nilai epoch 1-40 adalah estimasi berdasarkan kurva konvergensi yang umum untuk model ini.*

8.2 Analisis Hasil

Top-1 Accuracy 98,0% menunjukkan bahwa untuk 98 dari 100 gambar uji, kelas teratas yang diprediksi model adalah benar. Ini merupakan hasil yang sangat baik untuk klasifikasi 26 kelas dengan keragaman penampilan tangan yang tinggi.

Top-5 Accuracy 99,8% berarti hampir semua gambar (998 dari 1000) memiliki kelas yang benar dalam 5 prediksi teratas, menandakan model memiliki pemahaman representasi fitur yang sangat kuat.

Validation Loss 0,0557 yang jauh lebih rendah dari Training Loss 0,1177 menandakan model tidak mengalami overfitting — generalisasi model baik pada data yang belum pernah dilihat selama training.

9. Aplikasi Web Interface

Hasil model dikemas dalam aplikasi web interaktif menggunakan **Flask** sebagai backend dan **HTML + Tailwind CSS** sebagai frontend. Aplikasi dapat diakses melalui browser standar tanpa instalasi tambahan pada sisi klien.

9.1 Fitur Utama Aplikasi

Deteksi Kamera Real-Time

Tab kamera menggunakan WebRTC untuk mengambil frame dari webcam pengguna. Frame dikirim ke server Flask setiap interval waktu tertentu untuk diproses oleh model YOLOv11n-cls dan hasilnya ditampilkan langsung di halaman web beserta confidence score dan top-5 prediksi.

Upload Gambar untuk Deteksi

Pengguna dapat mengunggah gambar statis (JPG/PNG) untuk mendapatkan hasil klasifikasi. Cocok untuk pengujian dengan gambar referensi yang sudah ada.

Word Builder dengan Auto-Append

Setelah huruf terdeteksi, huruf tersebut secara otomatis ditambahkan ke rangkaian kata yang sedang dibangun. Pengguna dapat mengakhiri kata (tambah spasi), menghapus huruf terakhir, atau me-reset seluruh kata. Kata yang terbentuk dapat di-copy ke clipboard.

Text-to-Speech (TTS)

Setiap huruf yang terdeteksi langsung dibacakan menggunakan Web Speech API bawaan browser dalam Bahasa Indonesia. Suara diucapkan langsung berupa nama huruf (misalnya: 'A', 'B', 'C') tanpa jeda yang mengganggu.

Panduan Alfabet BISINDO

Tab panduan menampilkan galeri semua 26 huruf beserta gambar referensi. Pengguna dapat mengunggah foto referensi kustom untuk setiap huruf, serta mencoba deteksi langsung dari halaman panduan.

Evaluasi Model & Metrik

Tab evaluasi menampilkan grafik training (confusion matrix, kurva loss & akurasi) langsung dari folder hasil training Ultralytics.

9.2 Arsitektur Aplikasi (Endpoint API)

Endpoint	Method	Fungsi
/	GET	Halaman utama (index.html)
api/predict_frame	POST	Prediksi dari frame kamera (base64 JPEG)
api/predict_upload	POST	Prediksi dari file gambar yang diunggah
api/alphabet_reference	GET	Ambil gambar referensi semua huruf
api/upload_custom_reference	POST	Upload foto referensi kustom per huruf
api/reset_custom_reference	POST	Reset referensi kustom ke default dataset
dataset_sample/<class>/<file>	GET	Serve gambar sample dari dataset
training_metrics/<file>	GET	Serve grafik hasil training
static/references/	GET	Serve foto referensi kustom

10. Kesimpulan

Proyek ini berhasil membangun sistem pengenalan bahasa isyarat BISINDO untuk 26 kelas alfabet dengan tingkat akurasi yang sangat tinggi menggunakan pendekatan **klasifikasi gambar berbasis YOLOv11n-cls**. Berikut poin-poin kesimpulan utama:

- Model YOLOv11n-cls berhasil dilatih dengan **Top-1 Accuracy 98,0%** dan **Top-5 Accuracy 99,8%** pada dataset BISINDO 26 kelas.
- Pendekatan **klasifikasi terbukti lebih tepat** dibandingkan deteksi objek untuk kasus ini karena struktur dataset ImageFolder, single-instance per gambar, dan tidak adanya kebutuhan lokalisasi.
- Dataset dari **Roboflow Universe** dengan 51.312 gambar (augmentasi 3×) memberikan variasi yang cukup untuk model belajar fitur visual tangan yang robust.
- Transfer learning dari bobot pre-trained **mempercepat konvergensi** secara signifikan — model mencapai akurasi >94% bahkan pada epoch 10.
- Aplikasi web Flask yang dibangun **mendukung penggunaan real-world** dengan fitur kamera real-time, word builder, dan TTS — siap digunakan sebagai alat bantu komunikasi sederhana.
- Model berukuran kecil (**3,25 MB**) membuatnya mudah di-deploy di berbagai platform termasuk edge device dan server cloud dengan resource terbatas.

Saran Pengembangan Lanjutan

- Tambah deteksi gestur dinamis (kata/frasa BISINDO) menggunakan LSTM atau Transformer di atas backbone saat ini.
- Deploy model sebagai Progressive Web App (PWA) agar dapat berjalan offline di perangkat mobile.
- Perluas dataset dengan gambar dari berbagai kondisi pencahayaan, latar belakang, dan warna kulit untuk meningkatkan robustness.
- Implementasi model pruning dan quantization untuk deployment di mikrokontroler atau Raspberry Pi.
- Tambah dukungan angka dan simbol BISINDO selain 26 huruf alfabet.

11. Referensi

[1] Ultralytics. (2024). YOLOv11 Documentation. https://docs.ultralytics.com/

[2] Roboflow. (2026). BISINDO Dataset (sijewi-jjr8b/bisindo-wb1lk). Roboflow Universe. https://universe.roboflow.com/sijewi-jjr8b/bisindo-wb1lk

[3] Jocher, G., et al. (2024). Ultralytics YOLO (8.4.192) [Software]. Licensed under AGPL-3.0. https://github.com/ultralytics/ultralytics

[4] Redmon, J., & Farhadi, A. (2018). YOLOv3: An Incremental Improvement. arXiv:1804.02767.

[5] He, K., et al. (2016). Deep Residual Learning for Image Recognition. CVPR 2016. arXiv:1512.03385.

[6] Simonyan, K., & Zisserman, A. (2015). Very Deep Convolutional Networks for Large-Scale Image Recognition. ICLR 2015. arXiv:1409.1556.

[7] Paszke, A., et al. (2019). PyTorch: An Imperative Style, High-Performance Deep Learning Library. NeurIPS 2019.

[8] Flask Documentation. (2024). https://flask.palletsprojects.com/

[9] ReportLab. (2024). ReportLab PDF Library Documentation. https://www.reportlab.com/docs/reportlab-userguide.pdf

[10] Kemensos RI. (2020). Kamus Bahasa Isyarat Indonesia (BISINDO). Kementerian Sosial Republik Indonesia.